

Arten des Machine Learnings - Supervised, Unsupervised und Reinforcement Learning

Laura Hartzheim

2018

Inhaltsverzeichnis

1	Einleitung	1
2	Supervised Learning	2
2.1	Klassifikation	2
2.2	Regression	3
3	Unsupervised Learning	4
3.1	Clusterbildung	4
3.2	Dimensionsreduktion	5
3.3	Anomalie Erkennung	5
3.4	Association rule-mining	6
4	Reinforcement Learning	7
4.1	Umgebung	7
4.2	Einsatzbereiche	8
5	Schluss	9

1 Einleitung

2 Supervised Learning

Supervised Learning gehört zu den erfolgreichsten und meist verbreiteten Arten des Machine Learnings. [Mueller 2016] Beim Supervised Learning werden bekannte Daten und Ausgaben während dem Trainieren und Prüfen des Modells genutzt, welche auch Trainings-Daten und Label genannt werden. [Sarkar 2018] Diese optimieren das Modell, auf Basis der vorhandenen Daten, durch Anpassen der Parameter. [Suthaharan.2016] Ein Modell besteht aus den in- und output-Paaren des Training Datensatzes. [Mueller 2016] Das Hauptziel ist es die eingehenden Daten x auf die ausgehenden y Abzubilden ($f(x) = y$), um später für neue Daten x' die zugehörigen y' Daten zu bestimmen. [Sarkar 2018] Durch eine größere Menge an Trainings-Daten ist eine bessere Abdeckung von verschiedenen Fällen möglich, dies kann aber auch zu Overfitting führen. Um das zu verhindern muss das Training früh genug beendet werden. [Suthaharan.2016] Es gibt zwei Methoden für Supervised Learning: Klassifikation und Regression. Die Wahl der Methode hängt von der zu erfüllenden Aufgabe ab. [Sarkar 2018]

2.1 Klassifikation

Das Ziel der Klassifikation ist es ein Klassenlabel für die eingehenden Daten vorauszusagen. Die verschiedenen Label sind Teil einer vorgegebenen Liste. [Mueller 2016] Die Klassifikation kann in binäre und multiklassen Klassifikation aufgeteilt werden. Bei binärer Klassifikation sind nur zwei Klassen verfügbar, die Problemstellung lässt sich also auf eine Ja/Nein-Frage ableiten, die aussagt ob der Datensatz zu einer Klasse A gehört oder nicht und somit in Klasse B eingeordnet werden muss. Ein Beispiel hierfür ist das Verarbeiten von Daten einer Wettervorhersage (siehe 1). Aus den eingehenden Daten (Temperatur und Luftfeuchtigkeit) entscheidet das Supervised Modell ob es sich um die Klasse Sonne oder Regen handelt. [Mueller 2016]




Abbildung 1: Beispiel Wettervorhersage

In der multiklassen Klassifikation können die Inputdaten auf mehr als zwei Klassen aufgeteilt werden, es handelt sich also nicht mehr um eine Ja/Nein-Frage. [Mueller 2016] Während der Trainings-Phase werden Regeln für das Zuteilen von Labels erstellt, die später dabei helfen Test-Daten Labels zu zuweisen. [Suthaharan.2016]

2.2 Regression

In Regressions-Problemen sollen oft Zahlen oder Werte ermittelt werden. Im Gegensatz zur Klassifikation gibt es keine Klassen oder Label, denen Daten zugeordnet werden können. Regressions-Modelle lernen stattdessen den Zusammenhang aus Eingangs- und Ausgangsdaten, um für neue Daten den passenden Output vorherzusagen. [Sarkar 2018]

Abbildung 2 zeigt ein Beispiel bei dem mit Hilfe von Datensätzen, die Informationen zu Eiskäufen pro Minute und der Temperatur enthalten, eine Funktion gelernt werden konnte, um für zukünftige Temperaturen die passende Anzahl an Eiskäufen pro Minute auszugeben. [Sarkar 2018]




Abbildung 2: Beispiel Regression

Lineare Regressions Modelle versuchen mit nur einer Variable x eine Output-Variable y zu bestimmen und können somit lineare Probleme lösen. [Sarkar 2018] Multivariable Regressions Methoden werden für Probleme mit mehreren input-Variablen in Form eines Vektors und nur einer output-Variable verwendet. [Sarkar 2018] Ein Sonderfall der Multivariablen Regression ist die Polynomiale Regression. Hier ist die Ausgabevariable Polynom n -ten Grades der Eingangsvariable. [Sarkar 2018] Nichtlineare Regressions Modelle stellen zwischen ein- und ausgehenden Daten eine Beziehung auf Basis einer Kombination aus nicht-linearen Funktionen her. [Sarkar 2018]

3 Unsupervised Learning

Bei Unsupervised Learning haben die Trainings-Daten keine Label. [Sarkar 2018] Es ist also kein erwarteter Output bekannt und auch schwer feststellbar ob das Modell korrekte Ergebnisse erzielt. Der Algorithmus bekommt nur die Input-Daten. Er muss anhand dieser Entscheidungen treffen und kategorisieren. [Mueller 2016] Das Modell lernt inherente Strukturen, Muster und Beziehungen aus dem Datensatz, ohne dabei Hilfe von außen zu bekommen. [Sarkar 2018] Hierbei werden Besonderheiten von Daten gefunden. [Kirk 2014] Die Ergebnisse sind unsicherer als die von Supervised Learning Algorithmen. Sie eignen sich aber, um weitere Informationen zu den Daten zu finden. [Sarkar 2018] Deshalb wird diese Art des Machine Learnings oft in explorativen Bereichen eingesetzt, um Daten besser zu verstehen. Unsupervised Learning kann als Vorverarbeitungsschritt des Supervised Learnings eingesetzt werden. Hierbei sollen neue Representatoren für die Daten gefunden werden, um Genauigkeit, Speichernutzung und Geschwindigkeit zu verbessern. [Mueller 2016] Unsupervised Learning kann durch verschiedene Methoden angewendet werden: Clusterbildung, Dimensionsreduktion, Anomalie Erkennung und Association rule-mining. [Sarkar 2018] Diese werden im folgenden behandelt.

3.1 Clusterbildung

Ziel der Clusterbildung ist es, dass sich in einem Cluster möglichst ähnliche Daten befinden, dies sich zu den Daten, außerhalb des Clusters unterscheiden.(Müller, S.168) Die Cluster werden durch Muster, Ähnlichkeiten und Verbindungen zwischen den Datensätzen gebildet.(Sarkar, S.39) Zum Beispiel werden die Elemente in Abbildung 3 nach Formen in die Cluster rot, grün und blau eingeordnet. Die Clusterbildung kann in verschiedene Typen aufgeteilt werden: Centroid based, Hirachical clustering, distribution based und density based.(Sarkar, S.39)




Abbildung 3: Cluster

3.2 Dimensionsreduktion

Die Komplexität des Machine Learning Modells ist abhängig von der Anzahl der Inputs. Sie bestimmen die Zeit- und Speicherkomplexität, sowie die Anzahl der zum Training benötigten Daten. (Alpaydin, S.105) Dimensionsreduktion wird genutzt um den überladenen Input-Space zu verkleinern. Somit wird die Anzahl der relevanten Features oder Attribute ($\hat{=}$ Dimensionen) für jeden Datensatz reduziert. (Sarkar, S.40) Wenn die Modelle einfach gehalten werden, sind sie, aufgrund ihrer geringeren Varianz, bei kleinen Datensätzen robuster. (Alpaydin, S.105) Die Reduktion der Dimensionen erfolgt durch die Auswahl von Hauptfeatures und bedarfsgesteuerten Features. Für diese gibt es zwei Methoden. (Sarkar, S.40)

Für die Feature Extraction werden neue Features, die Kombinationen aus der original Featureliste sind, gesucht. (Alpaydin, S.106)

Bei der Feature Selection werden von d Dimensionen k , mit Hilfe von Subset Selection, ausgewählt. (Alpaydin, S.106) Die Features die die meisten Informationen liefern, werden aus der original Featureliste ausgewählt, der Rest wird verworfen. Es kommen keine neuen Features hinzu. (Sarkar, S.40) Ziel der Subset Selection ist es das beste Subset aus der Featureliste mit einer möglichst geringen Anzahl von Dimensionen und der besten Genauigkeit zu finden. Es gibt 2^d mögliche Subsets aus denen ausgewählt werden kann. Aufgrund der großen Menge können nicht alle getestet werden, deswegen müssen geeignete Verfahren für die Auswahl genutzt werden. (Alpaydin, S.106)

3.3 Anomalie Erkennung

Ziel der Anomalie Erkennung ist es, seltene oder laut vorherigen Datensätzen untypische Ereignisse zu erkennen, wie in Abbildung 4. Diese können auch nach bestimmten Mustern auftreten. In der Trainings-Phase sind alle Input-Daten ohne Anomalien. Danach kann der Algorithmus zwischen normalen und anomalen Datensätzen unterscheiden. (Sarkar, S.40)




Abbildung 4: Anomalie

3.4 Association rule-mining

Beim Association rule-mining werden Transaktionsdaten untersucht und analysiert um Muster und mögliche Regeln zu bestimmen. Diese Methode wird auch "market basket analysis" genannt, da sie oft genutzt wird um Einkaufsmuster zu erkennen. (Sarkar, S.41) In Abbildung 5 werden die verschiedenen Formen mit Association rule-mining analysiert. Das Ergebnis ist, dass der Kreis und das Quadrat häufig zusammen auftreten. Als neue Regel kann also zum Beispiel festgehalten werden, dass es sehr wahrscheinlich ist, dass sich ein Quadrat in einem Bereich befindet, wenn sich dort auch ein Kreis befindet.




Abbildung 5: Association rule-mining

4 Reinforcement Learning

Beim Reinforcement Learning werden intelligente Programme, auch genannt Agenten, eingesetzt.(Nandy, S.1) Hierbei gibt es keine Trainings-Daten.(Nandy, S.2) Ein Agent trainiert um sich seiner Umgebung anzupassen und seine Leistung zu verbessern.(Sarkar, S.42)

Er kennt den Zustand in dem sich seine Umgebung befindet und führt Aktionen aus die diesen verändern.(Alpaydin, S.376) Das Ausführen von Aktionen von einem Start- bis zu einem Endzustand nennt man Episode oder Prozess.(Alpaydin, S.377) Die Umgebung kann eine 2D oder 3D Simulation eines Szenarios aus der echten Welt oder aus einem Spiel sein. (Nandy, S.2) Die Wahl der Aktionen erfolgt durch Ausprobieren, da es sehr schwer ist von beginn an vorausszusagen welche Aktion in welchen Zustand ausgeführt werden muss.(Nandy, S.5) Der Agent besitzt bereits zu beginn bestimmte Strategien und Richtlinien, diese werden verbessert und angepasst.(Sarkar, S.43) Abhängig von der Interaktion mit der Umgebung erhält der Agent von der Umgebung Belohnungen und Bestrafungen, meist in form von plus und minus Punkten.(Nandy, S.2) Diese führen zu einem Update der Strategien, um später mehr Belohnungen zu erhalten.(Sarkar, S.42)

Reinforcement Learning wird auch lernen mit einem Kritiker genannt, da dem Mod-

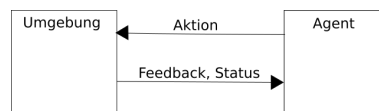


Abbildung 6: Umgebung mit Agent

ell im Lernprozess nicht vorgegeben wird was es tun soll, sondern erst nach dem ausführen der Aktionen eine Rückmeldung über diese an das Modell weitergegeben wird.(Alpaydin, S.374)

4.1 Umgebung

Die Umgebung des Agenten kann mit bestimmten Eigenschaften beschrieben werden, diese werden im folgenden erläutert.(Nandy, S.14)

Ist die Umgebung deterministisch gibt es für jede Aktion nur einen Übergang zu einem anderen Zustand, wenn nicht ist die Umgebung nicht-deterministisch und es sind mehrere Übergänge für jede Aktion möglich.(Nandy, S.14f)

Ist die Umgebung beobachtbar können wie bei zum Beispiel einem Schachspiel alle Informationen über die Umgebung wahrgenommen werden. Wenn die Umgebung nur teilweise beobachtbar ist sind bestimmte Informationen versteckt wie zum Beispiel beim Poker die Handkarten der anderen Mitspieler.(Nandy, S.15)

Eine Umgebung ist fortlaufend, wenn es mehr als eine Aktion gibt um zum nächsten Zustand zu gelangen. Ist sie beschränkt gibt es nur eine Aktion die zum nächsten Zustand führt.(Nandy, S.16)

Es gibt multi-agent Umgebungen, die für Problemstellungen mit mehrere Umgebungen, verschiedenen Aufgaben und ähnlichen Entscheidungen geeignet sind. Hier gibt es oft mehr als eine Aktion um zum nächsten Status zu gelangen. Dies wird durch Kommunikation zwischen den Agenten ermöglicht. Die Umgebung kann bei einer multi-agent Problemstellung dynamisch sein, das heißt, dass es Veränderungen der Umgebung an Interaktionsstellen geben kann. In single-agent Umgebungen gibt es nur eine Umgebung, da keine Kommunikation zwischen Agenten möglich ist. (Nandy, S.164)




Abbildung 7: Umgebung mit zwei Agenten

4.2 Einsatzbereiche

Reinforcement Learning wird in der Produktion von Robotern genutzt um Objekte von einer Box in eine andere zu befördern. In der Lagerverwaltung werden Transportzeiten zwischen Lagern verringert und die Platznutzung im Lager optimiert mit Hilfe von Reinforcement Learning. Die Fahrzeugnutzung in der Lieferverwaltung kann damit ebenfalls optimiert werden. (Nandy, S.22) Im Finanzbereich wird unter Verwendung von Handelsstrategien die Buchhaltung unterstützt.(Nandy, S.23)

5 Schluss