

Arten des Machine Learnings - Supervised, Unsupervised und Reinforcement Learning

Laura Hartzheim

2018

Inhaltsverzeichnis

| | | |
|----------|-----------------------------------|----------|
| 1 | Einleitung | 1 |
| 2 | Supervised Learning | 2 |
| 2.1 | Klassifikation | 2 |
| 2.2 | Regression | 2 |
| 3 | Unsupervised Learning | 4 |
| 3.1 | Clusterbildung | 4 |
| 3.2 | Dimensionsreduktion | 4 |
| 3.3 | Anomalie Erkennung | 5 |
| 3.4 | Association rule-mining | 5 |
| 4 | semi supervised? | 6 |
| 5 | Reinforcement Learning | 7 |
| 6 | Schluss | 8 |

1 Einleitung

2 Supervised Learning

Supervised Learning gehört zu den erfolgreichsten und meist verbreiteten Arten des Machine Learnings. (Müller, S.25) Beim Supervised Learning werden bekannte Daten und Ausgaben während dem Trainieren und Prüfen des Modells genutzt, welche auch Trainings-Daten und Label genannt werden. (Sarkar, S.35) Diese optimieren das Modell, auf Basis der vorhandenen Daten, durch Anpassen der Parameter. (Suthaharan, S.140) Ein Modell besteht aus den in- und output-Paaren des Training Datensatzes. (Müller, S.25) Das Hauptziel ist es die eingehenden Daten x auf die ausgehenden y Abzubilden ($f(x) = y$), um später für neue Daten x' die zugehörigen y' Daten zu bestimmen. (Sarkar, S.35) Durch eine größere Menge an Training-Daten ist eine bessere Abdeckung von verschiedenen Fällen möglich, dies kann aber auch zu Overfitting führen. Um das zu verhindern muss das Training früh genug beendet werden. (Suthaharan, S.140) Es gibt zwei Methoden für Supervised Learning: Klassifikation und Regression. Die Wahl der Methode hängt von der zu erfüllenden Aufgabe ab. (Sarkar, S.35)

2.1 Klassifikation

Das Ziel der Klassifikation ist es ein Klassenlabel für die eingehenden Daten vorauszusagen. Die verschiedenen Label sind Teil einer vorgegebenen Liste. (Müller, S.25) Die Klassifikation kann in binäre und multiklassen Klassifikation aufgeteilt werden. Bei binärer Klassifikation sind nur zwei Klassen verfügbar, die Problemstellung lässt sich also auf eine Ja/Nein-Frage ableiten, die aussagt ob der Datensatz zu einer Klasse A gehört oder nicht und somit zu in Klasse B eingeordnet werden muss. Ein Beispiel hierfür ist das Verarbeiten von Daten einer Wettervorhersage (siehe 1). Aus den eingehenden Daten (Temperatur und Luftfeuchtigkeit) entscheidet das Supervised Modell ob es sich um die Klasse Sonne oder Regen handelt.

In der multiklassen Klassifikation können die Inputdaten auf mehr als zwei Klassen aufgeteilt werden, es handelt sich also nicht mehr um eine Ja/Nein-Frage. (Müller, S.25) Während der Trainings-Phase werden Regeln für das Zuteilen von Labels erstellt, die später dabei helfen Test-Daten Labels zu zuweisen. (Suthaharan, S.8)

2.2 Regression

In Regressions-Problemen sollen oft Zahlen oder Werte ermittelt werden. Im Gegensatz zur Klassifikation gibt es keine Klassen oder Labels denen Daten zugeordnet werden können. Regressions-Modelle lernen stattdessen den Zusammenhang aus Eingangs- und Ausgangsdaten, um für neue Daten den passenden Output vorherzusagen. (Sarkar S.37)




Abbildung 1: Beispiel Wettervorhersage

Lineare Regressions Modelle versuchen mit nur einer Variable x eine Output-Variable y zu bestimmen und können somit lineare Probleme lösen.(Sarkar, S.37)

Multivariable Regressions Methoden werden für Probleme mit mehreren input-Variablen in Form eines Vektors und nur einer Output-Variable verwendet.(Sarkar, S.38)

Ein Sonderfall der Multivariablen Regression ist die Polynomiale Regression. Hier ist die Ausgabevariable Polynom n -ten Grades der Eingangsvariable (Sarkar, S.38)

Nichtlineare Regressions Modelle stellen zwischen Ein- und Ausgehendendaten eine Beziehung auf Basis einer Kombination aus nicht-linearen Funktionen her.(Sarkar, S.38)

3 Unsupervised Learning

Bei unsupervised Learning haben die Trainings-Daten keine Label. (Sarkar, S.38) Es ist also kein erwarteter/gewünschter Output bekannt und auch schwer feststellbar ob das Modell korrekte Ergebnisse erzielt. (Müller, S.132) Der Algorithmus bekommt nur die Input-Daten und muss anhand dessen Entscheidungen treffen und kategorisieren. (Müller, S.131)

Das Modell lernt inherente Strukturen, Muster und Beziehungen aus dem Datensatz ohne dabei Hilfe von außen zubekommen. (Sarkar, S.38) Hierbei werden Besonderheiten von Daten gefunden. (Kirk, S.16) Die Ergebnisse sind unsicherer als die von supervised Learning Algorithmen, eignen sich aber um weitere Informationen zu den Daten zu finden. (Sarkar, S.38) Weshalb diese Art des Machine Learnings oft in explorativen Bereichen eingesetzt wird um Daten besser zu verstehen. (Müller, S.132) Ein Einsatzgebiet ist als vorverarbeitungs Schritt des supervised Learnings, um neue Representatoren für die Daten zu finden und somit Genauigkeit, Speichernutzung und Geschwindigkeit zu verbessern. (Müller, S.132) Unsupervised Learning kann mit verschiedenen Methoden angewendet werden, diese sind: Clusterbildung, Dimensionsreduktion, Anomalie Erkennung und Association rule-mining. (Sarkar, S.38)

3.1 Clusterbildung

Ziel der Clusterbildung ist es, dass sich in einem Cluster möglichst ähnliche Daten befinden und außerhalb zum Cluster unterschiedliche. (Müller, S.168) Die Cluster werden durch Muster von Ähnlichkeiten und Verbindungen zwischen den Datensätzen gebildet. (Sarkar, S.39) Die Clusterbildung kann in verschiedene Typen aufgeteilt werden: Centroid based, Hierarchical clustering, distribution based und density based. (Sarkar, S.39)

3.2 Dimensionsreduktion

Die Komplexität des Machine Learning Modells ist abhängig von der Anzahl der Inputs. Sie bestimmen die Zeit- und Speicherkomplexität, sowie die Anzahl der zum Training benötigten Daten. (Alpaydin, S.105) Dimensionsreduktion wird genutzt um den überladenen Input-space zu verkleinern und somit die Anzahl der relevanten Features oder Attribute ($\hat{=}$ Dimensionen) für jeden Datensatz zu reduzieren. (Sarkar, S.40) Werden die Modelle einfach gehalten sind sie bei kleinen Datensätzen robuster aufgrund ihrer geringeren Varianz. (Alpaydin, S.105) Die Reduktion der Dimensionen erfolgt durch die Auswahl von Haupt- und bedarfsgesteuerten Features. Für diese gibt es zwei Methoden. (Sarkar, S.40)

Für die Feature Extraction werden neue Features, die Kombinationen aus der original Featureliste sind gesucht.(Alpaydin, S.106)

Bei der Feature Selection werden von d Dimensionen k , mit Hilfe von Subset Selection ausgewählt.(Alpaydin, S.106) Die Features die die meisten Informationen liefern werden aus der original Featureliste ausgewählt, der Rest wird verworfen, es kommen keine neuen Features hinzu.(Sarkar, S.40) Ziel der Subset Selection ist es das beste Subset aus der Featureliste mit einer möglichst geringen Anzahl von Dimensionen und der besten Genauigkeit zu finden. Es gibt 2^d mögliche Subsets aus denen ausgewählt werden kann, aufgrund der großen Menge können nicht alle getestet werden und es müssen geeignete Verfahren genutzt werden.(Alpaydin, S.106)

3.3 Anomalie Erkennung

Ziel der Anomalie Erkennung ist es seltene oder laut vorherigen Datensätzen untypische Ereignisse zu erkennen. Diese können auch nach bestimmten Mustern auftreten. In der Trainings-Phase sind alle Input-Daten ohne Anomalien, danach kann der Algorithmus zwischen normalen und anomalen Datensätzen unterscheiden.(Sarkar, S.40)

3.4 Association rule-mining

Beim Association rule-mining werden Transaktionsdaten untersucht und analysiert um Muster und mögliche Regeln zu bestimmen. Diese Methode wird auch "market basket analysis" genannt, da sie oft genutzt wird um Einkaufsmuster zu erkennen.(Sarkar, S.41)

4 semi supervised?

5 Reinforcement Learning

Beim Reinforcement Learning werden intelligente Programme, die Agenten genannt werden genutzt.(Nandy, S.1) Ein Agent trainiert um sich seiner Umgebung anzupassen und seine Leistung zu verbessern.(Sarkar, S.42) Die Umgebung kann eine 2D oder 3D Simulation eines Szenarios aus der echten Welt oder aus einem Spiel sein.(Nandy, S.2) Der Agent besitzt bereits zu beginn bestimmte Strategien und Richtlinien, diese werden verbessert und angepasst.(Sarkar, S.43)

6 Schluss